

# Regressão Linear

## Teoria e Prática



2021-01-09

# Agenda

- O que é e quando usar
- Parâmetro vs estimador
- Teste de Hipóteses e valor-p
- Interpretação dos parâmetros
- Desempenho: EQM e EPR
- Outliers
- Regressão Linear Múltipla
- Preditores Categóricos
- Transformações Não Lineares dos Preditores
- Interações
- Multicolinearidade
- Fazendo Predições
- Interpretabilidade da Predição
- Limitações da Regressão Linear
- Exercício para casa
- Sobreajuste (overfitting)
- Regularização
- LASSO e Seleção de Preditores
- Validação Cruzada

# Referências

- [Aprendizagem de Máquinas: Uma Abordagem Estatística \(Rafael Izbicki e Thiago Mendonça, 2020\)](#)
- [Introduction to Statistical Learning \(Hastie, et al\)](#)
- [Ciência de Dados: Fundamentos e Aplicações](#)

# Usos da Regressão Linear ("duas culturas")

- Predição
- Inferência

## Predição

Em muitas situações  $X$  está disponível facilmente mas,  $Y$  não é fácil de descobrir. (Ou mesmo não é possível descobri-lo).

$$\hat{Y} = \hat{f}(X)$$

é uma boa estimativa. Neste caso não estamos interessados em como é a estrutura  $\hat{f}$  desde que ela apresente predições boas para  $Y$ .

# Usos da Regressão Linear ("duas culturas")

- Predição
- Inferência

## Inferência

Em inferência estamos mais interessados em entender a relação entre as variáveis explicativas  $X$  e a variável resposta  $Y$ .

Por exemplo:

- Quais são as variáveis que estão mais relacionadas com a respostas?
- Qual a relação entre a resposta e cada um dos preditores?


# O que é e quando usar

## Regressão Linear Simples

$$y = \beta_0 + \beta_1 x$$

Exemplo:

$$dist = \beta_0 + \beta_1 speed$$



Ver [ISL](#) página 61 (Simple Linear Regression).


# O que é e quando usar

## Regressão Linear Simples

$$y = \beta_0 + \beta_1 x$$

Exemplo:

$$dist = \beta_0 + \beta_1 speed$$



Ver [ISL](#) página 61 (Simple Linear Regression).


# O que é e quando usar

## Regressão Linear Simples

$$y = \beta_0 + \beta_1 x$$

Exemplo:

$$dist = \beta_0 + \beta_1 speed$$



Ver [ISL](#) página 61 (Simple Linear Regression).



# O que é e quando usar

## Regressão Linear Simples

$$y = \beta_0 + \beta_1 x$$

```
# ajuste de uma regressão linear simples no R  
melhor_reta <- lm(dist ~ speed, data = cars)  
melhor_reta
```

```
##  
## Call:  
## lm(formula = dist ~ speed, data = cars)  
##  
## Coefficients:  
## (Intercept)      speed  
##    -17.579      3.932
```

Ver [ISL](#) página 61 (Simple Linear Regression).

# "Melhor Reta" segundo o quê?

Queremos a reta que **erre menos**.

Uma medida de erro: Erro Quadrático Médio.

$$EQM = \frac{1}{N} \sum (y_i - \hat{y}_i)^2$$

# "Melhor Reta" segundo o quê?

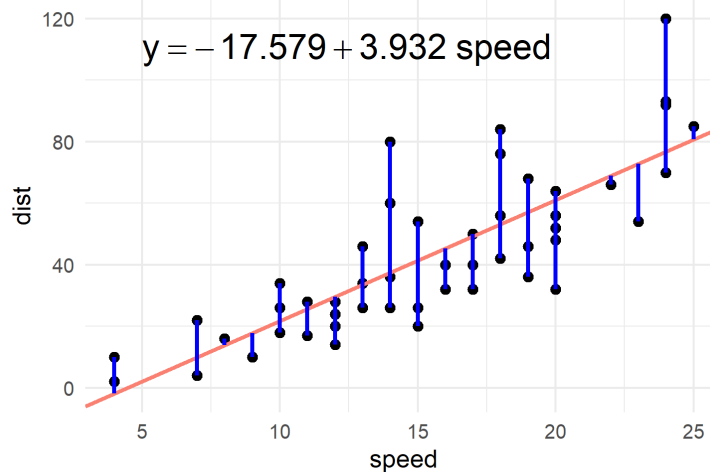
Queremos a reta que **erre menos**.

Uma medida de erro: **Erro Quadrático Médio**.

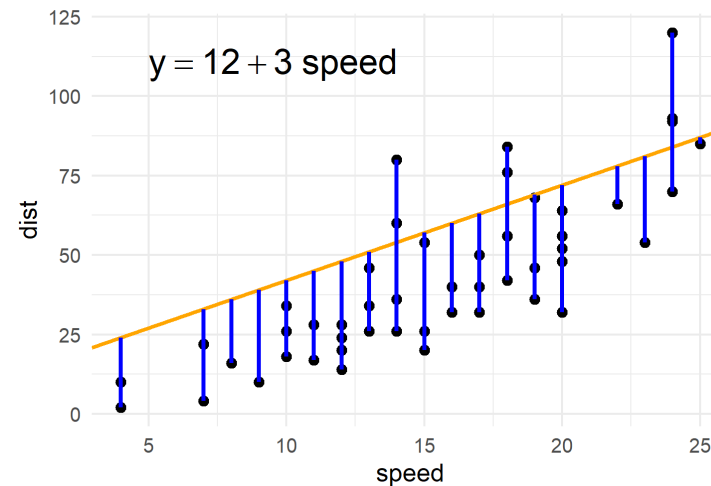
$$EQM = \frac{1}{N} \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x))^2$$

Os segmentos azuis quantificam o quanto o modelo errou naqueles pontos.

Resíduos da Melhor Reta



Resíduos da Reta Escolhida a Mão



# "Melhor Reta" segundo o quê?

Queremos a reta que **erre menos**.

Uma medida de erro: **Erro Quadrático Médio**.

$$EQM = \frac{1}{N} \sum (y_i - \hat{y}_i)^2$$

Ou seja, nosso **objetivo** é

Encontrar  $\hat{\beta}_0$  e  $\hat{\beta}_1$  que nos retorne o ~menor~ EQM.

... que é o mesmo que dizer "encontrar a melhor reta que explique os dados".

OBS: o EQM é a nossa **Função de Custo**.

*# lembrete: exercício 1 do script!*

# Qual o valor ótimo para $\beta_0$ e $\beta_1$ ?

No nosso exemplo, a nossa **HIPÓTESE** é de que

$$dist = \beta_0 + \beta_1 speed$$

Então podemos escrever o Erro Quadrático Médio como

$$EQM = \frac{1}{N} \sum (y_i - \hat{y}_i)^2 = \frac{1}{N} \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 speed))^2$$

Com ajuda do Cálculo é possível mostrar que os valores ótimos para  $\beta_0$  e  $\beta_1$  são

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Já que vieram do EQM, eles são chamados de **Estimadores de Mínimos Quadrados**.

# lembrete: exercício 2 do script!

## Depois de estimar...

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

### Exemplo:

$$\hat{dist} = \hat{\beta}_0 + \hat{\beta}_1 speed$$

Colocamos um  $\hat{\phantom{x}}$  em cima dos termos para representar "estimativas". Ou seja,  $\hat{y}_i$  é uma estimativa de  $y_i$ .

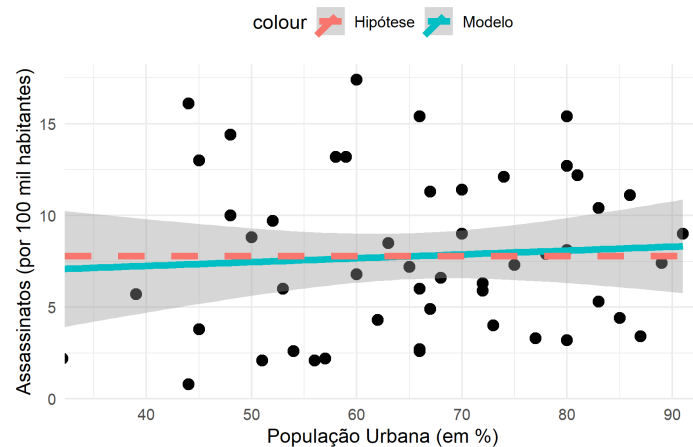
No nosso exemplo,

- $\hat{\beta}_0$  é uma estimativa de  $\beta_0$  e vale  $-17.579$ .
- $\hat{\beta}_1$  é uma estimativa de  $\beta_1$  e vale  $3.932$ .
- $\hat{dist}$  é uma estimativa de  $dist$  e vale  $-17.579 + 3.932 \times speed$ .

```
# Exercício: se speed for 15 m/h, quanto que  
# seria a distância dist esperada?
```

# Teste de Hipóteses e valor-p

Exemplo: relação entre População Urbana e Assassinos.



Modelo proposto:

$$y = \beta_0 + \beta_1 x$$

Hipótese do pesquisador:

"Assassinos não estão relacionados com a proporção de população urbana de uma cidade."

Tradução da hipótese em termos matemáticos:

$$H_0 : \beta_1 = 0 \quad vs \quad H_a : \beta_1 \neq 0$$

Se a hipótese for verdade, então o  $\beta_1$  deveria ser zero. Porém, os dados disseram que  $\hat{\beta}_1 = 0.02$ .

0.02 é diferente de 0.00?

# 0.02 é diferente de 0.00?

## Saída do R


```
##
## Call:
## lm(formula = Murder ~ UrbanPop, data = USArrests)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.537 -3.736 -0.779  3.332  9.728
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.41594    2.90669   2.207  0.0321 *
## UrbanPop     0.02093    0.04333   0.483  0.6312
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.39 on 48 degrees of freedom
## Multiple R-squared:  0.00484,    Adjusted R-squared:  -0.01589
## F-statistic: 0.2335 on 1 and 48 DF,  p-value: 0.6312
```



## 0.02 é diferente de 0.00?

Conceito importante: Os estimadores ( $\hat{\beta}_0$  e  $\hat{\beta}_1$  no nosso caso) têm distribuições de probabilidade.

Simulação de 1000 retas (ajustadas com dados diferentes).



## 0.02 é diferente de 0.00?

Conceito importante: Os estimadores ( $\hat{\beta}_0$  e  $\hat{\beta}_1$  no nosso caso) têm distribuições de probabilidade.


A Teoria Assintótica nos fornece o seguinte resultado:

$$t = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\beta_1}} \stackrel{a}{\sim} t(N - 2)$$

Em que

$$\hat{\sigma}_{\beta_1} = \sqrt{\frac{EQM}{\sum (x_i - \bar{x})^2}}$$

Usamos essas distribuições assintóticas para testar as hipóteses.



## 0.02 é diferente de 0.00?

Conceito importante: Os estimadores ( $\hat{\beta}_0$  e  $\hat{\beta}_1$  no nosso caso) têm distribuições de probabilidade.

A Teoria Assintótica nos fornece o seguinte resultado:

$$t = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\beta_1}} \stackrel{a}{\sim} t(N - 2)$$


No nosso exemplo, a hipótese é  $H_0 : \beta_1 = 0$ , então

$$t = \frac{0.02 - 0}{0.04} = 0.48$$

Em que


$$\hat{\sigma}_{\beta_1} = \sqrt{\frac{EQM}{\sum (x_i - \bar{x})^2}}$$

Usamos essas distribuições assintóticas para testar as hipóteses.




## 0.02 é diferente de 0.00?

Então agora podemos tomar decisão! Se a estimativa cair muito distante da distribuição t da hipótese 0, decidimos por **rejeitá-la**. Caso contrário, decidimos por **aceitá-la** como verdade.



```
## NO R:
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.41594    2.90669   2.207  0.0321 *
## UrbanPop     0.02093    0.04333   0.483  0.6312
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

# Interpretação dos parâmetros



$$y = \beta_0 + \beta_1 x$$

## Interpretações matemáticas

$\beta_0$  é o lugar em que a reta cruza o eixo Y.

$\beta_1$  é a derivada de Y em relação ao X. É quanto Y varia quando X varia em 1 unidade.

## Interpretações estatísticas

$\beta_0$  é a distância percorrida esperada quando o carro está parado (X = 0).

$\beta_1$  é o efeito médio na distância por variar 1 ml/h na velocidade do carro.

# Teste de Hipóteses e valor-p

## Exercício 3 do script:

No R, use a função `summary(melhor_reta)` (ver slide 9) para decidir se speed está associado com dist. Descubra o valor-p associado.

lembrete: o banco de dados se chama cars.

## Exercício 4 do script:

Interprete o parâmetro  $\beta_1$ .

# Intervalo de confiança para $\beta_1$

**Intervalo de 95%**

$$[\hat{\beta} - 1,96 * \hat{\sigma}_{\beta_1}, \hat{\beta} + 1,96 * \hat{\sigma}_{\beta_1}]$$

**Intervalo de 90%**

$$[\hat{\beta} - 1,64 * \hat{\sigma}_{\beta_1}, \hat{\beta} + 1,64 * \hat{\sigma}_{\beta_1}]$$

**Intervalo de  $1 - \alpha\%$**

$$[\hat{\beta}_1 - q_\alpha * \hat{\sigma}_{\beta_1}, \hat{\beta} + q_\alpha * \hat{\sigma}_{\beta_1}]$$

em que  $q_\alpha$  é o quantil da  $Normal(0, 1)$ .

Ver **ISL** página 66 (Assessing the Accuracy of the Model).

# O modelo está bom?

## EQM e EPR

ERP significa *Erro Padrão dos Resíduos* e é definido como

$$EPR = \frac{\sum (y_i - \hat{y}_i)^2}{N - 2} = \frac{SQR}{N - 2}$$

O 2 no denominador decorre do fato de termos **2 parâmetros** para estimar no modelo.

- Se  $y_i = \hat{y}_i \rightarrow EPR = 0 \downarrow$
- Se  $y_i \gg \hat{y}_i \rightarrow EPR = alto \uparrow$
- Se  $y_i \ll \hat{y}_i \rightarrow EPR = alto \uparrow$

Problema: Como sabemos se o EPR é grande ou pequeno?

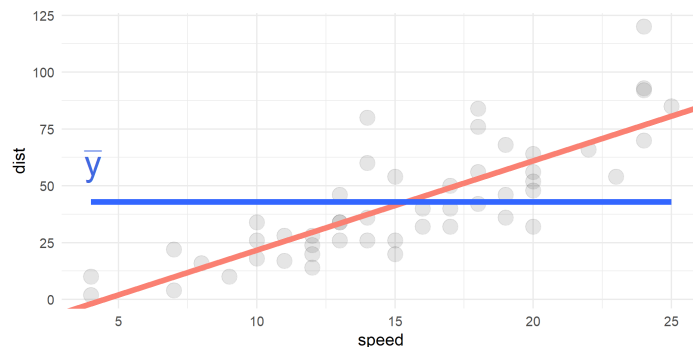
Ver **ISL** página 68 (Assessing the Accuracy of the Model).



# O modelo está bom?

## R-quadrado ( $R^2$ )

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{SQR}{SQT}$$



$R^2 \approx 1 \rightarrow SQR \ll SQT.$

$R^2 \approx 0 \rightarrow$  *reta* em cima da *reta*.

Problema do  $R^2$  é que ele sempre aumenta conforme novos preditores vão sendo incluídos.

Ver ISL página 68 (Assessing the Accuracy of the Model).

# O modelo está bom?


## R-quadrado ajustado

$$R^2 = 1 - \frac{SQR}{SQT} \frac{N - 1}{N - p}$$

Em que  $p$  é o número de parâmetros do modelo (no caso da regressão linear simples,  $p = 2$ ).

*# lembrete: exercícios 5 e 6 do script!*

# Outliers




Resíduo =  $y_i - \hat{y}_i$  (observado - esperado).

```
# lembrete: faça o exercício 7 do script
```

Ver [ISL](#) página 96 (Outliers).

# Outliers




Resíduo =  $y_i - \hat{y}_i$  (observado - esperado).

*# lembrete: faça o exercício 7 do script*


Ver [ISL](#) página 96 (Outliers).

# Outliers



Ver [ISL](#) página 96 (Outliers).

# Outliers



Ver [ISL](#) página 96 (Outliers).


# Outliers

## Distância de Cook

A distância de Cook mede o efeito de excluir uma dada observação.

$$D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2}{pEQM}$$

```
modelo <- lm(dist ~ speed, data)
plot(modelo)
cooks.distance(modelo)
```



Ver [Distância de Cook na Wikipedia](#).

# Outliers

## Diagnóstico

- Visualização univariada (histograma, boxplot);
- Comparação do valor com o desvio padrão;
- Distância de Cook

## Tratamentos

- Transformações  $\log()$ , etc;
- Categorização;
- Remover os valores extremos (raramente boa ideia);



# Regressão Linear Múltipla

## Regressão Linear Simples

$$y = \beta_0 + \beta_1 x$$

## Regressão Linear Múltipla

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

```
# ajuste de uma regressão linear múltipla no R
modelo_boston <- lm(medv ~ lstat + age, data = Boston)
summary(modelo_boston)
```


#	Estimate	Std.Error	t value	Pr(> t )
# (Intercept)	33.22	0.73	45.4	< 2e-16 ***
# lstat	-1.03	0.04	-21.4	< 2e-16 ***
# age	0.03	0.01	2.8	0.00491 **

Ver [ISL](#) página 71 (Multiple Linear Regression).

# Regressão Linear Múltipla

## Exemplo: Plano em vez de reta


Modelo: `lm(mpg ~ disp + wt, data = mtcars)`



# Preditores Categóricos

## Preditor com apenas 2 categorias

Saldo médio no cartão de crédito é diferente entre homens e mulheres?




```
summary(lm(Balance ~ Gender, data = Credit))  
# Coefficients:  
#  
#           Estimate Std. Error t value Pr(>|t|)  
# (Intercept)    509.80    33.13    15.389  <2e-16 ***  
# GenderFemale     19.73    46.05     0.429    0.669
```

Ver [ISL](#) página 84 (Predictors with Only Two Levels).

# Preditores Categóricos

## Preditor com apenas 2 categorias

Saldo médio no cartão de crédito é diferente entre homens e mulheres?



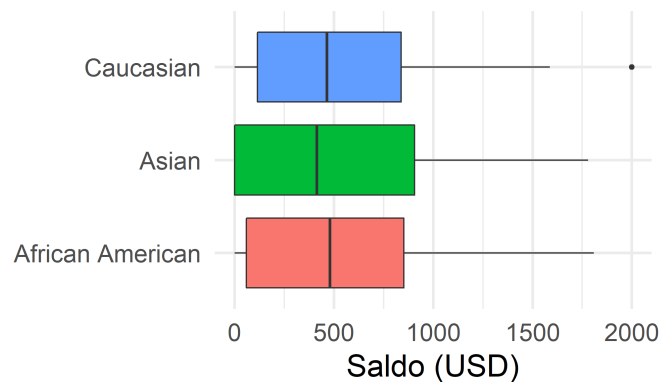
$$y_i = \beta_0 + \beta_1 x_i \quad \text{em que} \quad x_i = \begin{cases} 1 & \text{se a } i\text{-ésima pessoa for female} \\ 0 & \text{se a } i\text{-ésima pessoa for male} \end{cases}$$

*# lembrete: exercícios 8, 9 e 10 do script!*

Ver [ISL](#) página 84 (Predictors with Only Two Levels).

# Preditores Categóricos

## Preditor com 3 ou mais categorias



```
summary(lm(Balance ~ Ethnicity,  
#  
# (Intercept)      Estimate  S  
# EthnicityAsian    -18.69  6  
# EthnicityCaucasian -12.50  5
```

Modelo

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i}$$

Em que

$$x_{1i} = \begin{cases} 1 & \text{se for Asian} \\ 0 & \text{caso contrário} \end{cases}$$

$$x_{2i} = \begin{cases} 1 & \text{se for Caucasian} \\ 0 & \text{caso contrário} \end{cases}$$

# Preditores Categóricos

## Preditor com 3 ou mais categorias

"One hot encoding" ou "Dummies" ou "Indicadores".

<b>Ethnicity</b>	<b>(Intercept)</b>	<b>EthnicityAsian</b>	<b>EthnicityCaucasian</b>
Caucasian	1	0	1
Asian	1	1	0
Asian	1	1	0
Asian	1	1	0
Caucasian	1	0	1
Caucasian	1	0	1
African American	1	0	0
Asian	1	1	0

# Preditores Categóricos

## Preditor com 3 ou mais categorias

Interpretação dos parâmetros:

$$y_i = \begin{cases} \beta_0 & \text{se for Afro American} \\ \beta_0 + \beta_1 & \text{se for Asian} \\ \beta_0 + \beta_2 & \text{se for Caucasian} \end{cases}$$



```
# interprete cada um dos três parâmetros individualmente.  
# lembrete: exercício 11 do script!
```

# Transformações Não Lineares dos Preditores

## Exemplo: log

Modelo real:  $y = 10 + 0.5\log(x)$

Modelo proposto:  $y = \beta_0 + \beta_1\log(x)$



Outras transformações comuns: raiz quadrada, polinômios, Box-Cox, ...

*# lembrete: exercício 13 do script!*


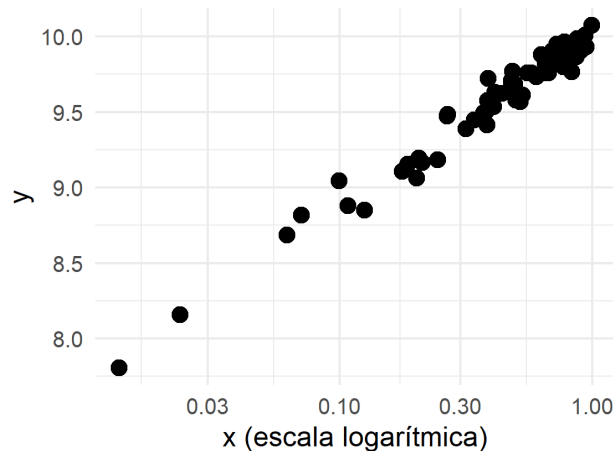


# Transformações Não Lineares dos Preditores

## Exemplo: log

Modelo real:  $y = 10 + 0.5\log(x)$

Modelo proposto:  $y = \beta_0 + \beta_1\log(x)$

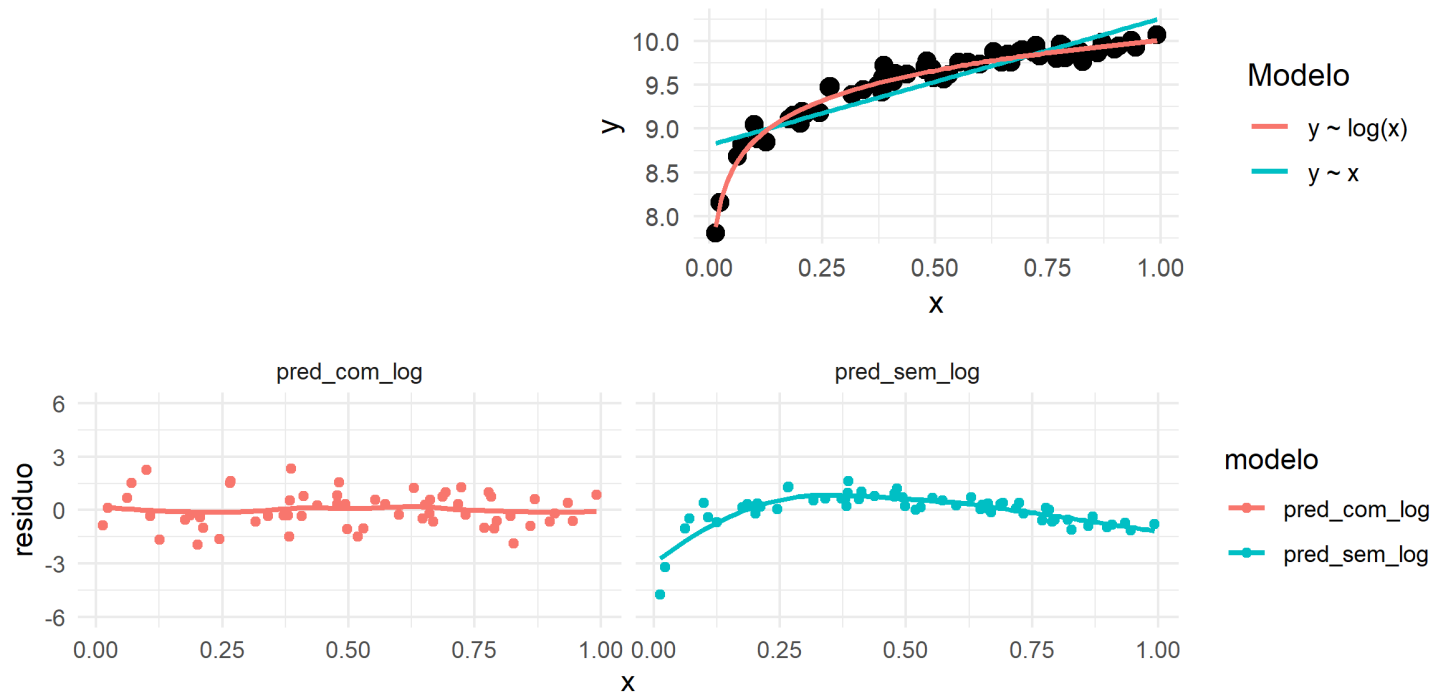


Outras transformações comuns: raiz quadrada, polinômios, Box-Cox, ...

*# lembrete: exercício 13 do script!*

# Transformações Não Lineares dos Preditores

## Gráfico de Resíduos




# Transformações Não Lineares dos Preditores

## Exemplo: Regressão Polinomial


Modelo real:

$$y = 500 + 0.4(x - 10)^3$$



Modelo proposto:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$




# lembrete: exercício 14 do script!

# Transformações Não Lineares dos Preditores

## Exemplo: Regressão Polinomial

Modelo real:

$$y = 500 + 0.4(x - 10)^3$$



Modelo proposto:


$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

y	x	x2	x3
456.5	5.3	28.2	149.7
492.5	7.4	55.4	412.2
548.4	11.5	131.3	1503.9
758.7	18.2	329.9	5993.0
444.7	4.0	16.3	65.6
748.3	18.0	322.8	5800.8
820.5	18.9	357.0	6744.3

*# lembrete: exercício 13 do script!*

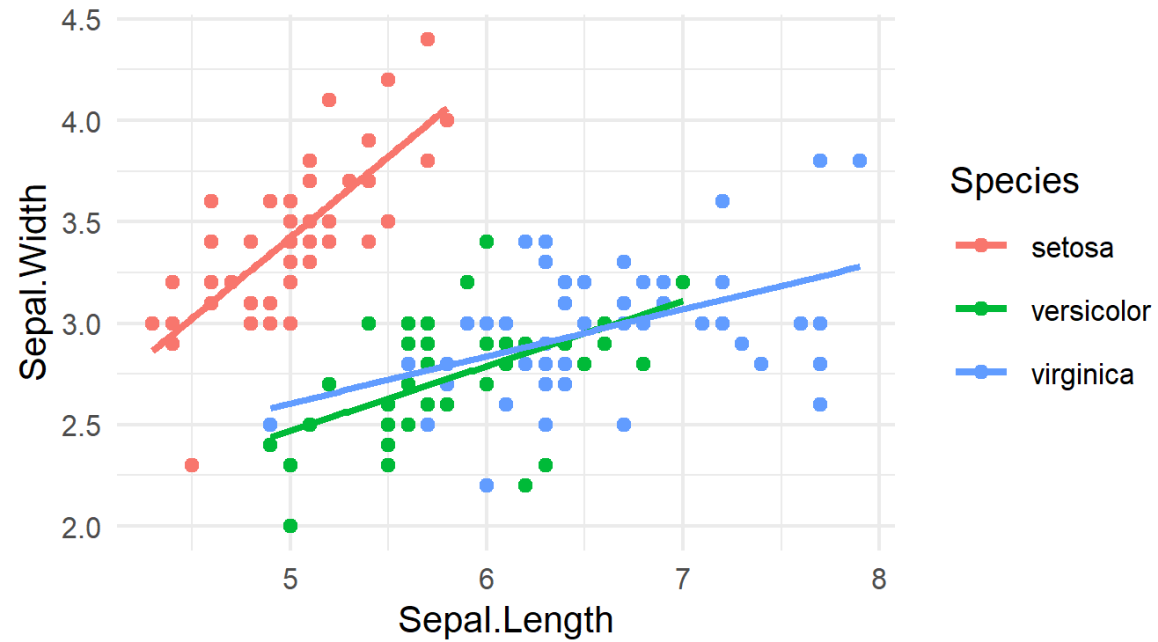
# Transformações Não Lineares dos Preditores

## Gráfico de Resíduos



# Interações


Interação entre duas variáveis explicativas: Species e Sepal.Length



# Interações

Modelo proposto (Matemático): Seja  $y = \text{Sepal.Width}$  e  $x = \text{Sepal.Length}$ ,

$$y = \beta_0 + \beta_1 x$$




Modelo proposto (em R): `Sepal.Width ~ Sepal.Length`

```
# lembrete: exercícios 14 ao 17 do script!
```

# Interações

Modelo proposto (Matemático): Seja  $y = \text{Sepal.Width}$  e  $x = \text{Sepal.Length}$ ,

$$y = \beta_0 + \beta_1 x + \beta_2 I_{\text{versicolor}} + \beta_3 I_{\text{virginica}}$$



Modelo proposto (em R): `Sepal.Width ~ Sepal.Length + Species`


```
# lembrete: exercícios 14 ao 17 do script!
```



# Interações

Modelo proposto (Matemático): Seja  $y = \text{Sepal.Width}$  e  $x = \text{Sepal.Length}$ ,


$$y = \beta_0 + \beta_1 x + \beta_2 I_{\text{versicolor}} + \beta_3 I_{\text{virginica}} + \beta_4 x I_{\text{versicolor}} + \beta_5 x I_{\text{virginica}}$$





Modelo proposto (em R): `Sepal.Width ~ Sepal.Length * Species`

```
# lembrete: exercícios 14 ao 17 do script!
```



# Heterocedasticidade



# Heterocedasticidade



# Heterocedasticidade



# Heterocedasticidade

## Problema

- O estimador  $\hat{\sigma}_{\beta_1} = \sqrt{\frac{EQM}{\sum (x_i - \bar{x})^2}}$  deixa de ter as melhores propriedades. Poderíamos ter conclusões estranhas para  $\beta_1$ .

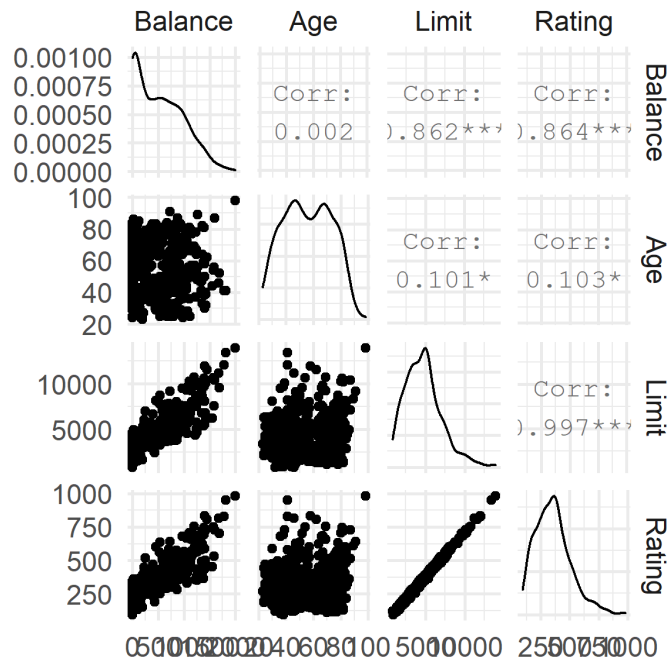
## Diagnóstico

- Visualização dos resíduos;

## Tratamentos

- Transformações na variável resposta.  $\log(y)$ ,  $\sqrt{y}$ ,  $1/y$ , etc;

# Multicolinearidade



Modelo 1: sem colineares

term	estimate	std.error	statistic	p.value
(Intercept)	-173.41	43.83	-3.96	0
Limit	0.17	0.01	34.50	0
Age	-2.29	0.67	-3.41	0

Modelo 2: com colineares

term	estimate	std.error	statistic	p.value
(Intercept)	-377.54	45.25	-8.34	0.00
Limit	0.02	0.06	0.38	0.70
Rating	2.20	0.95	2.31	0.02

Problema: Instabilidade numérica, desvios padrão inflados e interpretação comprometida.

Soluções: eliminar uma das variáveis muito correlacionadas ou Consultar o VIF (Variance Inflation Factor)

# Multicolinearidade

## VIF (Variance Inflation Factor)

Detecta preditores que são combinações lineares de outros preditores.

**Procedimento:** Para cada preditor  $X_j$ ,

- 1) Ajusta regressão linear com as demais:  $\text{lm}(X_j \sim X_{-1} + \dots + X_{-p})$ .
- 2) Calcula-se o R-quadrado dessa regressão e aplica a fórmula abaixo

$$VIF(\hat{\beta}_j) = \frac{1}{1 - R_{X_j|X_{-j}}^2}$$

- 3) Remova o preditor se VIF maior que 5 (regra de bolso).

```
# lembrete: exercícios 18 do script!
```

Ver **ISL** página 101.

# Fazendo Predições

## Modelo

```
modelo_iris <- lm(Sepal.Width ~ Sepal.Length * Species, data = iris)
```

Suponha que dados novos chegaram:

```
dados_novos <- tibble(Sepal.Length = 10, Species = "setosa")
```

## Utilizando a função `augment()` do pacote `broom`

```
augment(modelo_iris, newdata = dados_novos)
##   Sepal.Length Species .fitted .se.fit
## 1           10 setosa    7.42    0.553
```

O valor estimado de `Sepal.Width` foi de 7.42 +/- 0.55.



# Fazendo Predições

## Modelo

```
modelo_iris <- lm(Sepal.Width ~ Sepal.Length * Species, data = iris)
```

Suponha que dados novos chegaram:

```
dados_novos <- data.frame(Sepal.Length = 10, Species = "setosa")
```

## Utilizando a função `predict()`


```
dados_novos %>%  
  mutate(S.W.Est = predict(modelo_iris, newdata = dados_novos))  
##   Sepal.Length Species S.W.Est  
##           10 setosa      7.42
```

# Interpretabilidade da Predição

## LIME: Local Interpretable Model-agnostic Explanations

```
# fazendo lm com caret::train() pq o lime soh aceita caret  
modelo_iris <- train(Sepal.Width ~ Sepal.Length * Species, data = iris)  
explicador <- lime(iris, modelo_iris)  
explicacoes <- lime::explain(dados_novos, explicador, n_features = 2)  
plot_features(explicacoes)
```

```
# lembrete: exercícius 19  
# do script!
```



Ver [LIME for R](#) página 101.

## (Opcional) Abordagem Probabilística

Do ponto de vista probabilístico, modela-se o problema como uma amostra de  $N$  indivíduos, todos independentes entre si e com distribuição Normal.

$$Y_i|x_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, N$$

E então, supõem que a média de  $Y$  dado o valor de  $x$  seja linear:

$$\mu = E[Y|x] = \beta_0 + \beta_1 x$$

Assim, gostaríamos de achar  $\beta_0$  e  $\beta_1$  que fizessem dessa amostra a mais verossímil possível.

Daí entra o conceito de verossimilhança, que é a probabilidade conjunta dos dados acontecerem:

$$P(Y_1, \dots, Y_N|x) \stackrel{\text{indep}}{=} P(Y_1|x_1)P(Y_2|x_2) \dots P(Y_N|x_N)$$

continua...

## (Opcional) Abordagem Probabilística

Se tirarmos o *logarítmo* dessa probabilidade conjunta, teremos:

$$\log P(Y_1, \dots, Y_N | x) \stackrel{\text{indep}}{=} \log P(Y_1 | x_1) + \log P(Y_2 | x_2) + \dots + \log P(Y_N | x_N)$$

Que podemos escrever de forma mais sussinta usando um somatório:

$$\ell = \log P(Y_1, \dots, Y_N | x) = \sum_{i=1}^N \log P(Y_i | x_i)$$

Essa expressão que chamamos de  $\ell$  é conhecida como log-verossimilhança (log-likelihood no inglês).

continua...

## (Opcional) Abordagem Probabilística

Já que assumimos que  $Y_i|x_i$  segue uma distribuição  $N(\beta_0 + \beta_1 x_i, \sigma^2)$ , temos que:

$$\ell = \sum_{i=1}^N \log \left( \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{1}{2\sigma^2} (y_i - \mu_i)^2 \right] \right)$$

Que depois de simplificar (e deixando as constantes de fora), fica

$$\ell = -\frac{1}{N} \sum (y_i - \mu_i)^2 = -\frac{1}{N} \sum (y_i - (\beta_0 + \beta_1 \text{speed}))^2 = -EQM$$

Ou seja, maximizar a verossimilhança é equivalente a minimizar o EQM como vínhamos fazendo.

# Questões importantes


Questões que usualmente estamos interessados quando ajustamos uma regressão linear.

- Pelo menos um dos preditores  $X_1, X_2, \dots, X_p$  é útil para prever/explicar?
- Todos os preditores são úteis ou apenas um subconjunto deles que é?
- O quão bem o modelo se ajusta aos dados?

Ver **ISL** página 75 (Some Important Questions).


# Sobreajuste (overfitting)

Modelo real é de **grau 3**



# Sobreajuste (overfitting)


Modelo real é de **grau 3**





# Sobreajuste (overfitting)

Modelo real é de **grau 3**



Ver [ISL](#) página 61 (Simple Linear Regression).

# Regularização

Relembrando o nossa **função de custo** EQM.

$$EQM = \frac{1}{N} \sum (y_i - \hat{y}_i)^2 = \frac{1}{N} \sum (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_p x_{pi}))^2$$

Regularizar é "não deixar os  $\beta'$ s soltos demais".


$$EQM_{regularizado} = EQM + \lambda \sum_{j=1}^p |\beta_j|$$

Ou seja, **penalizamos** a função de custo se os  $\beta'$ s forem muito grandes.

Ver **ISL** página 203 (Linear Model Selection and Regularization).

# LASSO e Seleção de Preditores


Conforme aumentamos o  $\lambda$ , forçamos os  $\beta$ 's a serem cada vez menores.



Ver [ISL](#) página 219 (The LASSO).

# LASSO e Seleção de Preditores

Conforme aumentamos o  $\lambda$ , forçamos os  $\beta$ 's a serem cada vez menores.



Ver [ISL](#) página 219 (The LASSO).

# Validação Cruzada

```
## # 5-fold cross-validation
## # A tibble: 5 x 6
##   splits          id    n_treino n_teste regressao eqm_teste
##   <list>        <chr>    <dbl>   <dbl> <list>      <dbl>
## 1 <split [40/10]> Fold1      40      10 <lm>        17.0
## 2 <split [40/10]> Fold2      40      10 <lm>        13.0
## 3 <split [40/10]> Fold3      40      10 <lm>        12.2
## 4 <split [40/10]> Fold4      40      10 <lm>        15.7
## 5 <split [40/10]> Fold5      40      10 <lm>        19.6

## [1] 15.494
```

ERRO DE VALIDAÇÃO CRUZADA:

$$EQM_{cv} = \frac{1}{10} \sum_{i=1}^{10} EQM_{Fold_i} = 14,671$$

# Validação Cruzada

fold	speed	dist
fold 1	4	2
fold 1	4	10
fold 2	7	4
fold 2	7	22
fold 3	8	16
fold 3	9	10
fold 4	10	18
fold 4	10	26
fold 5	10	34
fold 5	11	17

# Limitações da Regressão Linear

- Variável resposta Não Normal
- Variável resposta Positiva
- Variável resposta Categórica
- Relação funcional não linear entre X e Y
- Muitas interações para testar entre as preditoras